
**VPP-EMS 적용을 위한 목적함수 기반의
최적 전력 분배 방법 연구**
최종보고서

머신러닝 기반 VPP 재생 에너지 최적 전력 분배 모델 개발

2023. 11. 26

제 출 문

한국에너지기술연구원 전력시스템연구팀 귀하

(주)에스티에스 엔지니어링은 VPP-EMS 적용을 위한 목적함수 기반의 최적 전력분배 방법 연구에 대해서 "머신러닝 기반 VPP 재생 에너지 최적 전력 분배 모델 개발" (연구개발 기간: 2023. 08. 28 ~ 2023. 11. 26)의 최종보고서 1부를 제출합니다.

2023. 11. 26

주식회사 에스티에스 엔지니어링 대표 이재빈, 황원식



연구책임자:
참여연구원:

이 재 빈
MAI VAN THUAN

<목 차>

1. 연구 개발 개요	1
2. 연구 개발 목적	1
1) 신뢰도기반 최적 전력 분배 모델 개발	1
2) 불확실성에 따른 민감도 분석	1
3) 머신러닝 모델 개발	1
3. 연구 개발 적용 이론	1
1) 발전 자원의 확률 분포 이론	1
2) 목표 신뢰도 기반 최적 전력 분배 모델 개발	4
3) 신뢰도지수(안전성지표; β) 개념	6
4) 비정규분포를 정규분포로 근사화 기법	7
5) 1차 가우스 근사를 이용한 AFOSM	10
6) 목표신뢰도 기반 알고리즘 순서도	13
4. 연구 개발 내용	13
1) 신뢰도 기반 최적 전력 모델 순서도	14
2) VPP-EMS 최적 전력 분배 모델 선정	14
3) 입력 데이터	15
5. 연구 개발 결과	17
1) 불확실성에 따른 태양광 발전량	17
2) ESS 방전량	20
6. 데이터 결과 활용 (머신러닝 모델)	21
1) 머신러닝 모델 개발 개요	21
2) 머신러닝 모델 개발 코드	21

1. 연구 개발 개요

본 '머신러닝 기반 VPP 재생 에너지 최적 전력 분배 모델 개발'은 한국에너지기술연구원 전력시스템연구팀에서 수행 중인 기본 사업 '출력 제한 문제 해결을 위한 융합형 VPP 핵심기술 개발'에서 지역(제주) 특화형 VPP 표준(운영 제어) 플랫폼 및 프로토콜 개발/실증을 위하여, VPP 자원(재생에너지, ESS, EV 등)의 최적 전력 분배 적용 모델을 개발하기 위한 과업이다.

2. 연구 개발 목적

아래의 목표를 달성하기 위해 최신 인공 지능 기술과 고급 예측 알고리즘을 활용한 최적 전력 분배 모델을 개발하고, 목적 함수 기반 최적 전력 분배 방법론과 비교 분석을 통해 검증한다. 이에 대한 내용은 코드 완료 보고서 형태로 정리하는데 있음.

- 1) 신뢰도기반 최적 전력 분배 모델 개발
- 2) 불확실성에 따른 민감도 분석
- 3) 머신러닝 모델 개발

[VPP 모델 적용 대상]

본 영역의 연구 결과는 제주지역 특화형 다종 VPP 자원에 대해서, 각기 다른 구성의 VPP 모델을 적용 대상으로 함.

[안정적인 에너지 공급 보장]

예측 모델을 통해 VPP 시스템이 재생 에너지 생산의 변동성을 관리하고, 안정적인 에너지 공급을 보장하는 기능을 개발.

[최적의 전력 분배 전략 제공]

모델은 재생 에너지 생산량을 바탕으로 최적의 전력 분배 전략을 제안할 수 있어야 하며, 이는 에너지 효율을 최대화하고 비용을 최소화하는데 중요한 역할을 함.

[적응성 및 유연성 강화]

VPP 재생에너지 예측 모델은 기후 변화, 시장 수요 변화, 기술 발전 등 다양한 환경 변화에 대응할 수 있도록 적응성 및 유연성을 강화하는 기능을 개발해야 함.

3. 연구 개발 적용 이론

- 1) 발전 자원의 확률 분포 이론

VPP-EMS 최적 전력 분배 모델을 개발하기 위하여 발전 자원의 확률 변수(혹은 입력 자료)의 확률 분포(확률밀도함수)가 필요하다. 따라서 입력조건 별로 적합한 확률 분포를 결정하는 것이 매우 중요하다. 본 연구에서는 태양광 발전의 확률 분포를 로그 정규 분포로 가정하였으며, 이와 관련된 이론을 정리하였다.

① 확률 변수

- 표본공간에서 정의되는 실수의 값을 갖는 함수를 일컬어 확률변수라고 하는데, 이러한 확률변수는 실험 결과가 항상 같지 않고 표본공간에서 이산성을 나타내는 변수를 의미한다. 이는 어떠한 규칙에 따라 또는 사상에 의해 정의되는 변수를 의미한다. 예를 들어 주사위를 굴러 나오는 수는 1, 2, 3, 4, 5 또는 6이 나올 수 있으며, 각각의 수가 나올 확률은 일정한 값을 갖는다는 가정하에 1/6이다. 어떠한 배관에 대한 작용압력 역시 그 결과가 동일하지 않고 이산성을 나타내며, 여러번을 시험하면 통계적 특성을 나타내게 된다. 이러한 변수들이 확률변수이다.
- 확률변수는 크게 이산확률변수와 연속확률변수로 구분될 수 있다. 여기서 이산확률변수는 확률변수의 값, 즉 표본공간이 유한개의 요소로 이루어진 변수를 의미한다. 주사위던지기가 이산확률변수의 예로 들 수 있다. 연속확률변수는 임의의 구간에 내에서 어떠한 값도 가능한 변수를 의미한다. 예를 들면, 재료의 항복강도, 배관에 대한 작용압력, 또는 차량의 급제동거리 등이 있다. 확률변수는 표본공간에서 정의한 확률의 개념을 좌표축 상에 확장시킬 수 있다. 이때 확률변수의 값에 관계되는 확률의 값을 그림으로 표현한 것이 확률밀도함수, 확률질량함수, 누적분포함수 등으로 구분된다.

② 확률밀도함수

- 확률밀도함수는 연속되는 값을 갖는 확률변수 X 에 대하여 x 의 존재확률을 나타내는 함수로, 확률변수는 각각의 고유한 확률분포를 갖는다. 연속확률변수에 대한 확률밀도함수($f_X(x)$)를 임의의 구간($a \leq x \leq b$)에서 적분개념으로 도식화하면 아래 그림과 같다. 또한 이를 수식으로 정식화하면 다음 식으로 표현된다.




그림. 확률밀도함수

$$\int_a^b f_X(x)dx = A : area$$

- 여기서 A는 임의의 $(a \leq x \leq b)$ 구간에서의 확률변수가 존재할 확률이며, 기하학적으로 확률밀도함수의 구간면적을 의미한다.
- 확률변수에 필요한 파라미터는 평균, 분산, 그리고 표준편차가 있으며 각각은 다음의 식에서 차례대로 나타내었다.

$$\mu_X = E(X) = \int_{-\infty}^{\infty} Xf(X)dX$$

$$V[X] = \int_{-\infty}^{\infty} X^2 f(X)dX - \mu_X^2$$

$$\sigma_X = \sqrt{V[X]}$$

- 또한 변동계수(Coefficient of Variation; COV)는 본 평가의 입력 데이터로서 확률변수의 불확실성을 나타내며, 이는 평균과 표준편차의 관계를 이용하여 아래의 식과 같이 표현된다.

$$COV = \frac{\sigma_X}{\mu_X}$$

- 확률분포는 분포형을 결정하고 그 특성을 나타는 값인 파라미터를 갖는다. 이러한 파라미터의 예로는 평균과 표준편차가 있으며, 분포형에 따라 더 많은 파라미터가 필요한 경우도 있다. 이처럼 각각의 확률분포에 따라 다른 분포형태를 나타내며, 보다 많은 파라미터를 갖기 때문에 다양한 확률분포에 따른 특성 및 차이점 등에 대한 연구가 필요하다.

③ 표준정규분포

- 다양한 형태의 정규분포를 유일한 하나의 분포로 만든 것을 표준정규분포라고 하며, 평균이 '0'이고 표준편차가 '1'인 경우를 말한다. 표준정규분포의 경우에는 각 구간별 확률이 표로 주어져 있어서 본 연구에서도 마찬가지로 특정구간의 확률을 쉽게 구하여 활용할 수 있었다. 표준정규분포를 나타내는 함수는 다음의 식과 같으며, 확률변수 x 가 정규분포라면 표준정규분포 확률변수

z 에 대한 변환은 다음의 식과 같이 표현된다.

$$f(z) = \frac{1}{\sqrt{2\pi}} \cdot e^{-\frac{z^2}{2}}, \quad z \in (-\infty, \infty)$$

$$z = \frac{x - \mu}{\sigma}$$

④ 대수정규분포

- 확률변수에 자연대수를 취한 값이 정규분포를 따르면, 그 변수는 대수정규분포를 따른다고 한다. 대수정규분포에는 Gamma 분포와 Weibull 분포 등 음의 값이 없는 확률변수에 가장 많이 적용되는 분포 중의 하나다. 대수정규분포는 다음의 식과 같이 표현된다.

$$f(x) = \frac{1}{x\sigma_{\ln X}\sqrt{2\pi}} \cdot e^{-\frac{(\ln x - \mu_{\ln X})^2}{2\sigma_{\ln X}^2}}, \quad x \in (0, \infty)$$

2) 목표 신뢰도 기반 최적 전력 분배 모델 개발

① 하중-강도 계수 설계법(Load and Resistance Factor Design; LRFD)

- 본 연구에서는 목표 신뢰도 기반 최적 전력 분배 모델 개발을 위해 하중-강도 계수 설계법을 이용하였다. 이 기법은 한계상태함수(Limit-state function)를 구성하는 하중과 강도에 대하여 개별적으로 안전계수를 설정(부분안전계수)하는 것이 가능하다. 이는 신뢰성 공학에 근거한 부분안전계수의 설정 기법으로서 해외 토목업계 및 석유화학업계 등에서 적극적으로 검토되고 있다. 또한 한계상태 설계 기법으로도 불리고 있으며, 시공 및 사용기간 중에 구조물이 수행할 것으로 예상되는 기능을 상실하는 상태(한계상태)를 명확히 하여, 그 가능성이 충분히 적도록 신뢰성 이론에 바탕을 둔 구조물의 설계 기법으로 정의될 수 있다.
- 일반적으로 파손에 대한 목표신뢰도의 판정은 작용하는 하중의 상한치와 재료강도의 하한치와의 대소 관계 비교에 의해 이루어지며, 기존 결정론적 평가법에서는 재료 및 외력의 불확실성으로서 실험적, 경험적 가정에 근거한 안전계수가 포함되어 왔다. 여기에 비해 불확실성을 고려한 설계는 하중과 강도의 통계적 특성을 고려하고 신뢰성 공학 기법을 응용하여 각 변수의 불확실성의 차이에 의해 변수 별로 안전계수를 설정하는 합리적인 평가를 수행하도록 하는 것이다. 이러한 개념은 확률밀도와 부재의 강도 및 작용 하중과의 관계를

나타내는 아래 그림과 같이 하중-강도 모델($L-R$ 모델)로 설명될 수 있다. 이 모델은 부재의 강도와 작용 하중이 단일 값이 아닌 분포로 나타내어지며, 부재의 파손은 강도변수(R)보다 하중변수(L)가 크게 평가되는 부분($R < L$)에서 생기는 것을 의미한다. 따라서 하중-강도계수 설계법에 이용되는 한계상태함수는 다음과 같이 정의된다.

$$G = R - L$$

$G > 0$: 안전, $G < 0$: 비안전, $G = 0$: 한계상태




그림 2.3.5 $L-R$ 모델

② 최적 전력 분배 모델 적용

- 하중-저항 계수 설계 개념에서 하중과 저항에 대한 한계상태식이 필요하며, 이는 VPP-EMS 최적 전력 모델에서 발전량과 발전계획에 대한 발전비용식과 동일한 개념이 적용될 수 있다. 이를 다음과 같이 정의한다.

$$G = J = (P_{pv} + P_{ch}) - P_{dch}$$

$G > 0$: 과잉충전, $G < 0$: 과잉방전, $G = 0$: 최적충전상태

- 과잉충전 시 발전 비용이 증가하고, 과잉방전 시 발전 비용이 감소한다. 발전 비용을 최소화하기 위하여 방전량을 늘려야 하지만, 발전 계획량과 발전량 및 ESS 용량을 고려하여 최적 충전 상태를 찾는 것이 중요하다. 이는 하중-저항 상태 설계법과 동일한 개념으로 적용 가능하다.

3) 신뢰도지수(안전성지표: β) 개념

- 기본 확률변수 $X = (X_1, X_2, \dots, X_n)$ 는 정규분포형태라 가정하고, 한계상태함수를 $G(X)$ 라 할 때, 신뢰도지수(β)를 정의하기 위해서는 먼저 기본 변수를 정규화할 필요가 있다. 기본 변수로부터 정규화된 새로운 변수 $Z = (Z_1, Z_2, \dots, Z_n)$ 는 다음과 같이 정의된다. 하중-저항 설계법에서는 한계상태함수라고 지칭하지만, 본 적용 모델에서는 최적상태함수로 정의하겠다.

$$Z_i = \frac{X_i - \mu_X}{\sigma_X}, \quad i = 1, 2, \dots, n$$

- 여기서 μ_X 및 σ_X 는 확률 변수 X_i 의 평균치 및 표준편차이다. 특히 FORM 중 정규화 함수를 이용한 부분안전계수 계산 방법은 위 식과 같은 기본 변수 정규화 과정을 통하여 각 확률 변수를 정규화할 필요가 있다.




그림. 신뢰도지수 β

- 아래 식은 정규화된 새로운 변수로 최적상태함수를 다시 설정하기 위하여 식과 같이 각 확률변수(X_1, X_2, \dots, X_n)에 따라 정규화 함수로 표현되어 최적상태 함수에 입력된다.

$$X_i = \mu_i + Z_i \sigma_i$$

- X 좌표계의 최적 상태 면은 Z 좌표계의 최적 상태 면에 사상되는데, 일반적으로 Z 좌표계의 원점은 안전영역 내에 존재하게 된다. 위 그림에 2차원의 예를 나타내었다. 그림에서 신뢰도지수 β 는 거리 OA 로 정의되며 이때 점 A 를 최적상태점이라 한다.

- 이를 바탕으로 신뢰도지수 β 는 다음과 같이 정식화될 수 있다.

$$\beta = \min \left[\sum_{i=1}^n Z_i \right]^{1/2}$$

- 기본 변수 $X_i (i=1, 2, \dots, n)$ 가 정규분포에 따르면, 신뢰도지수 β 와 최적 전력 분배 확률 P_f 와의 관계는 표준정규분포함수(Φ)를 이용하여 다음과 같이 정식화 될 수 있다.

$$P_f = \Phi(-\beta) = 1 - \Phi(\beta)$$

- 전술한 바와 같이 신뢰도지수 β 는 최적상태함수(G)의 정의식과 그 정의식에 포함되는 확률변수의 통계적 특성, 즉, 평균치, 표준편차 및 확률밀도함수가 설정되어 있음을 전제로 하여 구해진다. 또한, 신뢰도지수는 위 그림과 같이 비선형의 최적 상태면을 가질 경우, 반복에 의한 수렴 계산으로 구해지며, 그 값은 $G=0$ 을 만족하는 최적점(Z^*)에서 평가된다.

4) 비정규분포를 정규분포로 근사화 기법

- 목표신뢰도에 대한 최적 전력 분배를 평가하기 위해서 평가대상의 확률변수가 비정규분포인 경우 정규분포의 확률변수로 근사화해서 발전 비용 함수로 설정한 최적상태함수에 계산되어야 한다.
- 그 이유는 목표신뢰도, 즉 안전성지표의 개념이 표준정규분포상의 최적상태함수 곡선과 원점사이의 최단거리로 정의되기 때문에 비정규분포 변수와 정규분포 변수로 이루어진 최적상태함수를 계산하기 위해서는 차원을 표준정규분포로 같게 만들어 동일한 차원에서 계산되어야 하기 때문이다.
- 이를 위해서 본 연구에서는 비정규분포를 정규분포로 근사화하는 Rackwitz-

Fiessler 기법을 이용하였다. 이 기법은 비정규분포인 대수정규분포의 최적점 (Z_i)에 대한 근사화된(등가의) 평균과 표준편차를 각각 μ_i, σ_i 이라 할 때, 표준정규분포의 확률분포함수와 확률밀도함수가 비정규분포의 확률분포함수와 확률밀도함수가 각각 같다고 가정할 때 다음의 식으로 표현될 수 있으며, 이를 간략히 도식화하면 아래의 그림으로 표현될 수 있다.

$$\Phi\left(\frac{Z_i - \mu_i}{\sigma_i}\right) = F_{Z_i}(Z_i)$$

$$\frac{1}{\sigma_i} \times \phi\left(\frac{Z_i - \mu_i}{\sigma_i}\right) = f_{Z_i}(Z_i)$$

- 여기서 Φ 와 ϕ 는 각각 표준정규 확률분포함수 및 확률밀도함수이며, $F_{Z_i}(Z_i)$ 와 $f_{Z_i}(Z_i)$ 는 비정규분포의 확률분포함수 및 확률밀도함수이다.




그림. 임의의 확률변수(Z^*)에 대한 정규분포 근사화 도식도

- 위의 그림은 임의의 확률변수에서의 넓이, 즉 확률이 같다고 가정하였을 때 임의의 확률밀도함수와 정규분포의 확률밀도함수 사이의 관계를 보여주고 있다.
- 한편 대수정규분포의 확률분포함수 및 확률밀도함수는 다음 식과 같이 각각 표준정규분포의 확률분포함수 및 확률밀도함수로 정의된다.

$$F_{Z_i}(Z_i) = \Phi \left[\frac{\log Z_i - E[\log Z_i]}{D[\log Z_i]} \right]$$

$$f_{Z_i}(Z_i) = \frac{1}{Z_i \cdot D[\log Z_i]} \times \phi \left[\frac{\log Z_i - E[\log Z_i]}{D[\log Z_i]} \right]$$

- 여기서, $E[\log Z_i]$ 와 $D[\log Z_i]$ 는 비정규분포의 확률변수(Z_i)에 \log 를 취한 $\log[Z_i]$ 의 평균과 표준편차를 의미한다.
- 이 기법의 가정된 식과 대수정규분포와 정규분포의 관계식을 연립하면 아래의 식으로 전개할 수 있다.

$$\frac{Z_i - \mu_i}{\sigma_i} = \frac{\log Z_i - E[\log Z_i]}{D[\log Z_i]}$$

- 또한 이 기법의 가정된 확률밀도함수 식과 대수정규분포와 정규분포의 관계식을 연립하여 전개하면 아래의 식을 도출할 수 있다.

$$\frac{1}{\sigma_i} \times \phi \left(\frac{Z_i - \mu_i}{\sigma_i} \right) = \frac{1}{Z_i \cdot D[\log Z_i]} \times \phi \left[\frac{\log Z_i - E[\log Z_i]}{D[\log Z_i]} \right]$$

- 연립한 두 식을 정규분포로의 근사화하고자 하는 비정규분포의 확률변수(Z_i)에 대한 평균(μ_i)과 표준편차(σ_i)로 전개하면 다음과 같다.

$$\sigma_i = Z_i \cdot D[\log Z_i] \times \frac{\phi \left(\frac{Z_i - \mu_i}{\sigma_i} \right)}{\phi \left[\frac{\log Z_i - E[\log Z_i]}{D[\log Z_i]} \right]}$$

$$\mu_i = Z_i - \sigma_i \times \frac{\log Z_i - E[\log Z_i]}{D[\log Z_i]}$$

- 마지막으로, 구하고자하는 비정규분포(대수정규분포)를 정규분포의 근사된 평균(μ_i)과 표준편차(σ_i)를 앞서 계산된 두 식에 의해서 구할 수 있다. 참고로 위의 두 식을 일반화하면 다음과 같다.

$$\sigma_i = \frac{\phi(\Phi^{-1}(F_{Z_i}(Z_i)))}{f_{Z_i}(Z_i)}$$

$$\mu_i = Z_i - \sigma_i \Phi^{-1}(F_{Z_i}(Z_i))$$

5) 1차 가우스 근사를 이용한 AFOSM

- FORM 중 1차 가우스 근사를 이용한 AFOSM의 특성상 정규분포를 가지는 확률변수는 변환과정이 필요 없지만, 비정규분포를 가지는 확률변수는 변환과정을 통해 정규분포로 가정하는 것을 전제로 하였다. 이 신뢰도지수법의 큰 특징은 최적상태함수를 최적점 중심의 Taylor 급수 전개를 통하여 1차항까지 고려하여 계산하는 것이다.
- 다음은 수행한 FORM 중 1차 가우스 근사를 이용한 AFOSM을 이용한 최적점을 계산하는 방법의 알고리즘을 순서대로 정리한 것이다.

[1st step] 목표파손확률의 입력

각 운전 환경에 따른 목표최적확률을 입력하고 아래 식에 나타난 목표최적확률(P_f)과 목표신뢰도지수(β)의 관계를 이용하여 신뢰도지수를 구한다.

$$P_f = \Phi(-\beta) = 1 - \Phi(\beta)$$

[2nd step] 각 확률변수의 데이터 입력

각 확률변수에 대하여 평균값과 COV값을 입력하게 되는데, 이 값들을 통해 각 변수의 표준편차가 계산된다. 또한 모든 확률변수가 정규분포를 따르지 않기 때문에 각 변수에 대하여 분포형을 결정해야 한다. 예를 들어, 대수정규분포의 경우에는 분포변환을 통하여 정규분포형을 갖도록 정규분포 변환과정을 거쳐야 한다. 정규분포로 변환하려면 우선 기본확률변수가 X 의 평균(μ_N)과 표준편차(σ_N)를 이용하여 $\ln X$ 의 평균(μ_{LN})과 표준편차(σ_{LN})를 구해야 한다.

$$\mu_{LN} = e^{0.5\mu_N + \sigma_N^2}$$

$$\sigma_{LN} = \sqrt{\mu_N^2 (e^{\sigma_N^2} - 1)}$$

위 관계식을 이용하여 $\ln X$ 의 평균과 표준편차를 구한 후, 이를 이용하여 다음의 관계식을 통해 정규분포로 근사한 등가의 평균(μ_e)과 표준편차(σ_e)를 구한다.

$$\mu_e = \mu_N(1 - \ln \mu_N + \mu_{LN})$$

$$\sigma_e = \mu_N \sigma_{LN}$$

[3rd step] 초기 방향벡터 (α_i) 설정

α_i 는 확률변수에 대한 방향벡터를 의미한다. 초기의 α_i 는 확률변수의 갯수(n)에 따라 $1/\sqrt{n}$ 로 결정할 수 있다.

[4th step] 초기 최적점 계산

목표최적확률(목표신뢰도)에 대한 최적상태함수의 최적점을 계산하기 위한 주어진 목표신뢰도 β 와 방향벡터 α_i 를 이용하여 표준정규분포상의 초기의 최적점 x_i^1 을 아래의 식을 이용하여 구할 수 있다.

$$x_i^1 = -\alpha_i \times \beta$$

여기서 최적점(x_i^1)의 상첨자는 반복계산의 횟수, 즉 초기의 파괴점을 의미하고, 하첨자는 변수의 개수, 즉 첫 번째 변수를 나타낸다.

[5th step] 최적상태함수의 설정 및 편미분 계산

VPP-EMS 최적 전력 분배를 위한 목적 함수를 기반으로 최적상태함수를 정의하고, 정의된 최적상태함수를 아래 식과 같이 최적점 중심의 Taylor 급수 전개를 통하여 1차항까지 고려한다.

$$G(X_1, X_1, \dots, X_n) \approx G(x_1^*, x_2^*, \dots, x_n^*) + \sum_{i=1}^n (X_i - x_i^*) \frac{\partial G}{\partial X_i} \Big|_{x^*}$$

그런 다음, 각 확률변수에 대하여 편미분하면 그 값은 아래와 같다.

$$\frac{\partial G}{\partial X_i} = \frac{\partial G}{\partial X_i} \Big|_{x^*}$$

여기서, 편미분 값은 파괴점(x_i^*)을 대입하여 구할 수 있다. 단, 초기의 파괴점은 평균으로 설정한다.

Simulation To Solution

[6th step] 방향벡터(α_i)의 재설정

방향벡터를 아래와 같이 정의를 이용하여 구하고 난 다음, Newton-Raphson법의 원리를 사용하여 초기에 설정한 방향벡터 값과 반복계산을 1회 수행한 후의 방향벡터 값의 차이가 지정해준 오차범위보다 이상일 경우를 수렴판정하여 α_i 의 재설정을 수행한다.

$$\alpha_i = \frac{\left[\frac{\partial G}{\partial X_i} \right]_{x^*} \sigma_{X_i}}{\left\{ \sum_{i=1}^4 \left[\frac{\partial G}{\partial X_i} \right]_{x^*}^2 \sigma_{X_i}^2 \right\}^{\frac{1}{2}}}$$

여기서 σ_{X_i} 는 파괴점에 대한 표준편차로서 정규화함수를 이용한 FORM과 달리 정규변수의 편미분 값을 직접 구하기 어려워 다음과 같은 관계식을 이용하여 식을 변형시켜 방향벡터를 계산할 수 있다.

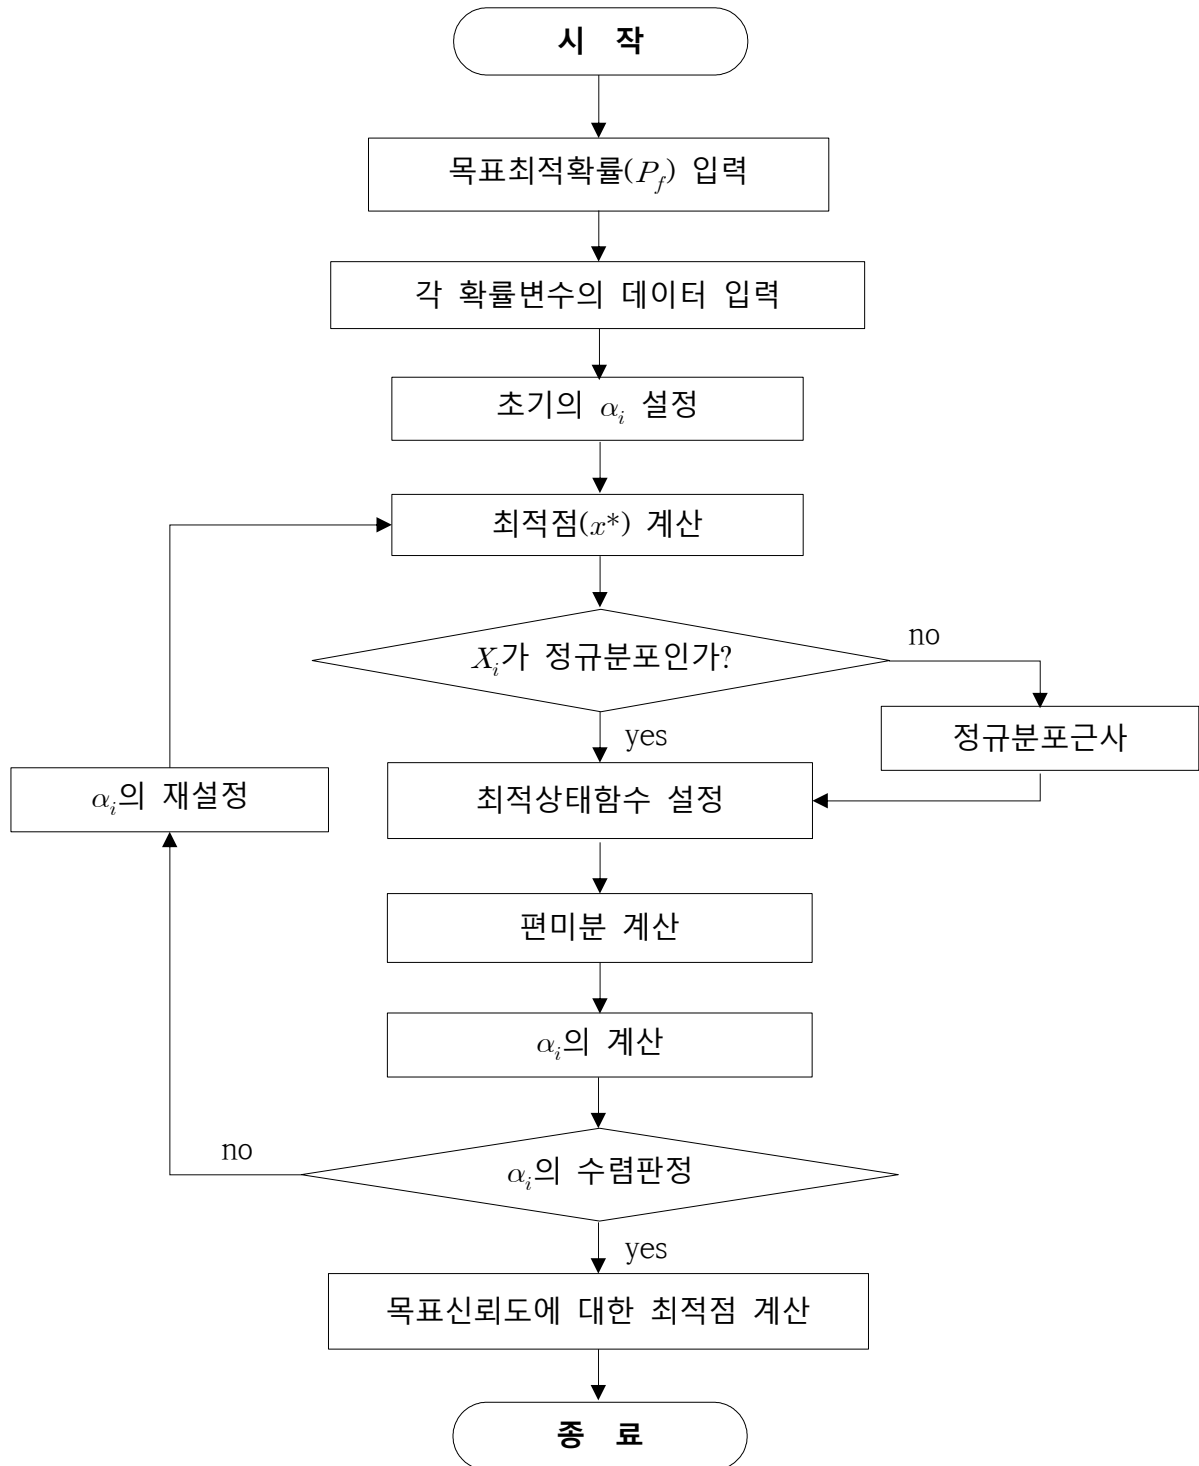
$$\frac{\partial G}{\partial Z_i} = \frac{\partial G}{\partial X_i} \sigma_{X_i}$$

[7th step] 최적 상태점 산출

α_i 의 수치반복계산을 통해 수렴할 때의 최적점을 아래 식을 이용하여 산출한다.

$$x_i^* = \mu_{X_i} - \alpha_i \beta \sigma_{X_i}$$

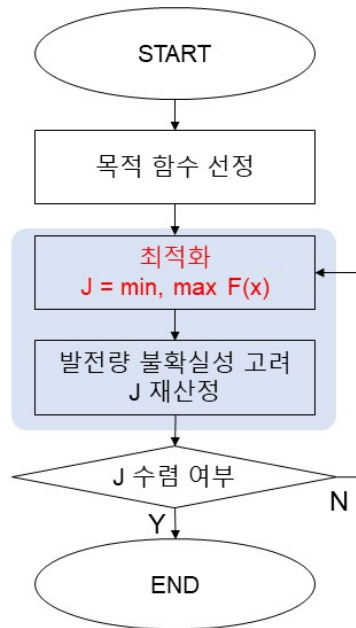
6) 목표신뢰도 기반 알고리즘 순서도



4. 연구 개발 내용

본 연구에서는 간단한 태양광 발전 비용 함수를 선정하고, 태양광 발전의 불확실성을 고려하였을 경우와 고려하지 않았을 경우를 비교 분석하였다. 또한, 불확실성에 대한 민감도를 평가하였다.

1) 신뢰도 기반 최적 전력 모델 순서도



2) VPP-EMS 최적 전력 분배 모델 선정

- 본 연구에서는 발전의 불확실성을 고려한 신뢰도 기반 최적 전력 분배 모델을 개발하기 위하여 발전 자원의 비용 함수를 다음과 같이 정의하였다.

$$J(t) = \sum_{k=1}^N c_g(k)P_g(t+k) + c_b\{P_{ch}(t+k) + P_{dch}(t+k)\}$$

$$c_g = \text{SMP} - \text{cost of generation } (P_g \leq 0)$$

- 태양광 발전소의 경우 Cost of Generation = 0이다. 발전소의 이익을 최대화 하기 위해서는 위의 비용 함수를 최소화하는 것이 필요하다. 위 식에 대한 제한 조건은 다음과 같이 가정하였다.

$$P_g = P_{ch} + P_{dch} + P_{pv}, \quad P_g : \text{발전계획량}$$

$$S(k+1) = S(k) + \eta P_{ch}(k) + 1/\eta P_{dch}(k), \quad S_{min} \leq S(k) \leq S_{max}$$

$$P_{min} \leq P_{ch} + P_{dch} \leq P_{max}, \quad P_{ch} : \text{ESS 충전량}, P_{dch} : \text{ESS 방전량}$$

$$P_{dch} \leq 0 \leq P_{ch}, \quad P_g \leq 0$$


- 발전 비용의 최적화는 선형 계획법으로 수행하였으며, 아래의 표와 같이 각 변수를 가정하였다.


Variables	Values	Unit	Remark
ESS 용량	500	kWh	
S_Min	50	kWh	10%
S_Max	450	kWh	90%
P_min	-120	Kw	
P_max	120	Kw	
c_g	0.7		발전비
c_b	0.7		ESS감가비
η	1		ESS효율

- 태양광 발전 확률분포모델은 대수정규분포로 선정하였으며, 평균은 태양광 발전 예측값으로 가정하였다. 또한, 불확실성에 따른 민감도를 평가하기 위하여 COV는 0.1, 0.2, 0.3으로 고려하였다.
- 또한 본 연구에서의 목표 신뢰도는 2.0, 2.5, 3.0으로 고려하여 각 목표 신뢰도에 따른 최적 전력 분배량을 비교 분석하였다.

3) 입력 데이터

- 시간에 따른 태양광 발전량 P_{pv} 와 발전계획량 P_g 는 아래 그림과 같이 가정하였다.






5. 연구 개발 결과

1) 불확실성에 따른 태양광 발전량


① $\beta = 2$

k(hours)	Reference	Cov = 0.1	Cov = 0.2	Cov = 0.3
0	0	0	0	0
1	0	0	0	0
2	0	0	0	0
3	0	0	0	0
4	0	0	0	0
5	1.7	1.39	1.12	0.91
6	5.7	4.65	3.76	3.04
7	13.9	11.33	9.17	7.40
8	21	17.12	13.86	11.18
9	14.2	11.57	9.37	7.56
10	18.8	15.32	12.41	10.01
11	27.5	22.41	18.15	14.64
12	20	16.30	13.20	10.65
13	25.7	20.95	16.96	13.68
14	20.7	16.87	13.66	11.02
15	9.8	7.99	6.47	5.22
16	8.9	7.25	5.87	4.74
17	5.1	4.16	3.37	2.72
18	1.8	1.47	1.19	0.96
19	0	0	0	0
20	0	0	0	0
21	0	0	0	0
22	0	0	0	0
23	0	0	0	0




② $\beta = 2.5$

k(hours)	Reference	Cov = 0.1	Cov = 0.2	Cov = 0.3
0	0	0	0	0
1	0	0	0	0
2	0	0	0	0
3	0	0	0	0
4	0	0	0	0
5	1.7	1.32	1.02	0.78
6	5.7	4.42	3.41	2.62
7	13.9	10.78	8.31	6.39
8	21	16.28	12.55	9.66
9	14.2	11.01	8.49	6.53
10	18.8	14.58	11.24	8.64
11	27.5	21.32	16.44	12.64
12	20	15.51	11.95	9.20
13	25.7	19.93	15.36	11.82
14	20.7	16.05	12.37	9.52
15	9.8	7.60	5.86	4.51
16	8.9	6.90	5.32	4.09
17	5.1	3.95	3.05	2.34
18	1.8	1.40	1.08	0.83
19	0	0	0	0
20	0	0	0	0
21	0	0	0	0
22	0	0	0	0
23	0	0	0	0




③ $\beta = 3.0$

k(hours)	Reference	Cov = 0.1	Cov = 0.2	Cov = 0.3
0	0	0	0	0
1	0	0	0	0
2	0	0	0	0
3	0	0	0	0
4	0	0	0	0
5	1.7	1.25	0.92	0.67
6	5.7	4.20	3.09	2.26
7	13.9	10.25	7.52	5.52
8	21	15.49	11.37	8.34
9	14.2	10.48	7.69	5.64
10	18.8	13.87	10.18	7.46
11	27.5	20.29	14.89	10.92
12	20	14.75	10.83	7.94
13	25.7	18.96	13.91	10.20
14	20.7	15.27	11.21	8.22
15	9.8	7.23	5.30	3.89
16	8.9	6.57	4.82	3.53
17	5.1	3.76	2.76	2.02
18	1.8	1.33	0.97	0.71
19	0	0	0	0
20	0	0	0	0
21	0	0	0	0
22	0	0	0	0
23	0	0	0	0




2) ESS 방전량


① $\beta = 2.0$



② $\beta = 2.5$



③ $\beta = 3.0$



6. 데이터 결과 활용 (머신러닝 모델)

1) 머신러닝 모델 개발 개요

- 상위 거래시스템에 의해 결정된 VPP 목표값을 기반으로 VPP 모델을 구성하고, 목적 함수 및 제한 조건에 대하여 몬테카를로 알고리즘을 통해 학습데이터를 구축함.
- 빅데이터 분석 및 처리
 - 1) 시계열 경향 분석
 - 2) Raw 데이터 왜곡(skewness) 분석
- 하이퍼파라미터에 대한 케이스 스터디
 - 1) 히든레이어 및 퍼셉트론 개수
 - 2) Dropout 비율
 - 3) 최적화 함수 (Adam) 또는 SGD (확률적 경사하강법) 사용 여부
 - 4) 학습 batch 수 또는 학습율 최적화
 - 5) 테스트 데이터 비율 등
- 머신러닝 모델은 Python기반의 KERAS라이브러리를 활용하여 개발하며, MLDP (Multi-Layers Deep Perceptron)의 심층 학습으로 개발함.
- 신뢰성 향상을 위하여 앙상블 모델을 적용하고, 이에 대한 최적 모델을 개발함.

2) 머신러닝 모델 개발 코드

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from scipy import stats
from sklearn.model_selection import train_test_split
from sklearn import preprocessing
from sklearn.preprocessing import LabelEncoder
from scipy.stats import boxcox
import matplotlib.pyplot as plt

from keras.models import Sequential
from keras.layers import Dense, PReLU, LeakyReLU, Dropout
from keras.callbacks import EarlyStopping
from keras.utils import to_categorical
from keras import optimizers
import tensorflow as tf
```



```
from sklearn.metrics import explained_variance_score, mean_squared_error,
mean_absolute_error, r2_score

data = pd.read_csv('sample.csv',encoding="UTF-8-sig")
df = pd.DataFrame(data)
df.info()
df.describe()

Dratio=0.05

feature = ['PV','PG']
label_1 = ['Pch', 'Pdch']
x_train_1, x_valid_1, y_train_1, y_valid_1 = train_test_split(data[feature], data[label_1], test_size=0.2, random_state=1)

#lrelu= lambda x: tf.keras.activations.relu(x, alpha=0.3)

# 2. 모델 구성하기
model_1 = Sequential()
model_1.add(Dense(120, input_dim=3, activation=PReLU(alpha_initializer="zeros")))
model_1.add(Dropout(Dratio))
model_1.add(Dense(60, activation=PReLU(alpha_initializer="zeros")))
model_1.add(Dropout(Dratio))
model_1.add(Dense(20, activation=PReLU(alpha_initializer="zeros")))
model_1.add(Dropout(Dratio))
model_1.add(Dense(5, activation=PReLU(alpha_initializer="zeros")))
model_1.add(Dropout(Dratio))
model_1.add(Dense(1))

# 3. 모델 학습과정 설정하기
adam = optimizers.Nadam(lr=0.0001)
sgd = optimizers.SGD(lr=0.001, decay=1e-6, momentum=0.9, nesterov=True)
model_1.compile(optimizer=adam, loss='mse', metrics=['mae'])

# 4. 모델 학습시키기
hist_1 = model_1.fit(x_train_1, y_train_1, epochs=300, batch_size=3000)
```

```
# 4. 모델 평가하기
pred_2 = model_1.predict(x_valid_1)
pred_1 = pd.DataFrame(pred_2, columns = label_1)

print(r2_score(y_valid_1, pred_1))
print(r2_score(y_train_1, model_1.predict(x_train_1)))
```